

PRIMEROS PASOS, PRIMERAS ALUCINACIONES CON LLMs

¿Cómo empezar a usar LLMs desde cero?

| ¿QUÉ ES REALMENTE UN LLM?

PROBABILIDAD Y PREDICCIÓN

Un LLM no "entiende" conceptos;
predice la siguiente palabra (token)
basándose en probabilidades
estadísticas derivadas de su
entrenamiento masivo con grandes
cantidades de datos.

AUTOATENCIÓN Y CONTEXTO

Utiliza arquitecturas **Transformer** para
procesar secuencias. Los mecanismos
de autoatención permiten que el
modelo "recuerde" tokens previos para
generar texto coherente.

LOS PILARES DE SU FUNCIONAMIENTO



PATRONES

Aprende patrones complejos del lenguaje humano, no conocimiento en sí.



ESCALA

Entrenado con billones de parámetros y volúmenes de datos enormes.



GENERALIZACIÓN

Capacidad de adaptarse a tareas para las que no fue específicamente entrenado.

Y SOBRE TODO...

Fácil de utilizar para el usuario final

PERSPECTIVAS DE INTERACCIÓN

PERSPECTIVA USUARIO

Enfoque en **Prompt y Output**. Interacción simple a través de lenguaje natural para tareas inmediatas.



PERSPECTIVA DESARROLLADOR

Control total del **Contexto**. Gestión de mensajes estructurados, system prompts e integración vía API con sistemas externos.

```
messages = [  
    {"role": "system", "content": "Eres un experto en IA"},  
    {"role": "user", "content": "Explicame qué es un LLM"}  
]
```

TOKENS: LA UNIDAD FUNDAMENTAL

El token no siempre es igual a una palabra. Es la unidad mínima de procesamiento que impacta directamente en:

- ✓ **Coste:** Se factura por volumen de tokens procesados.
- ✓ **Límites:** Cada modelo tiene una ventana de contexto finita.
- ✓ **Latencia:** A mayor número de tokens, mayor tiempo de respuesta.

Método	Ejemplo tokenización de "revolutionary"
Whitespace	"revolutionary"
Character-level	"r", "e", "v", ...
WordPiece (BERT)	"revol", "##ution", "##ary"
BPE (GPT-2)	"revolution", "ary"
SentencePiece	"_revol", "ution", "ary"

LA ERA DEL CONTEXTO

Arquitectura RAG: Retrieval-Augmented Generation

EL FLUJO DE TRABAJO RAG

Un LLM es tan bueno como el contexto que recibe. RAG permite inyectar datos útiles y relevantes que permiten mejorar el rendimiento sin reentrenamiento:

- ⬇ **Recuperar:** Extraer datos relevantes de fuentes externas.
- + **Inyectar:** Añadir esa información al prompt dinámicamente.
- ⚡ **Generar:** El LLM produce una respuesta más informada.



MECÁNICA DE RECUPERACIÓN



EMBEDDINGS

Conversión de texto a vectores numéricos que representan el significado semántico.



BÚSQUEDA VECTORIAL

Identificación de información similar en un espacio multidimensional de alta densidad.



SIMILITUD

El sistema encuentra los fragmentos más relevantes basándose en el concepto, no solo palabras clave.

ESTRATEGIA Y MEJORES PRÁCTICAS


- ✓ **Especificidad:** Sé extremadamente detallado en los prompts para reducir ambigüedad.
 - ✓ **Validación:** Usa validadores de formato y structured outputs (JSON) para integraciones.
 - ✓ **Iteración:** Evalúa constantemente la calidad del output frente a modelos base.
 - ✓ **Optimización:** Controla el tamaño de la ventana de contexto para gestionar latencia.
 - ✓ **Gestión de Errores:** Define comportamientos fallback cuando el modelo no tiene datos suficientes.
 - ✓ **Seguridad:** Limita el acceso a datos sensibles mediante capas de filtrado.
-

LIMITACIONES DE LOS LLM



Alucinaciones

Generan respuestas incorrectas o ficticias con total confianza estadística.



Falta de Datos

No conocen tus datos ni contexto interno

Sensibilidad

No tienen memoria real; el resultado depende críticamente del prompt dado.

¿CUÁNDO USAR VS NO USAR LLMS?

Dimensión	Uso Recomendado (LLM)	Evitar LLM
Datos	✓ Texto no estructurado (Correos)	✗ Cálculo exacto / Tablas
Lógica	✓ Ambigüedad y Resúmenes	✗ Reglas deterministas
Operación	✓ Generación de ideas / Código	✗ Lógica crítica de negocio
Factor Crítico	✓ Interacción en Lenguaje Natural	✗ Sistemas sensibles a fallos

TRADE-OFFS

↑ Calidad

↑ Coste

↓ Latencia

↓ Precisión

↑ Más contexto

↑ Coste / Latencia

↑ Tamaño del modelo

↑ Costo / requisitos de hardware

¿QUÉ PODEMOS HACER?

- Conversar → Chatbots
- Buscar → RAG
- Actuar → Agentes
- Estructurar → Extracción
- Analizar → Clasificación

